

Business Analytics & Data Science

Día 4: Probabilidad y Distribuciones

EAE Business School Barcelona

4 de junio de 2026

Plan del Día 4

Primera Parte (8:30-10:45)

1. ¿Qué es la probabilidad?
2. Reglas básicas de probabilidad
3. Probabilidad condicional
4. Variables aleatorias y distribuciones discretas

Segunda Parte (11:15-13:30)

1. La distribución normal
2. Trabajar con distribuciones en Python
(`scipy.stats`)
3. Regla 68-95-99.7 y z-scores
4. ¿Son normales los precios? + evaluación

Bloque 2: Estadística con Python

Días 1-3: Python, pandas, limpieza y visualización

Hoy empezamos estadística: el lenguaje para razonar sobre la **incertidumbre**

- **Día 4 (hoy):** probabilidad y distribuciones
- **Día 5:** estadísticos de resumen
- **Día 6:** inferencia (intervalos de confianza, p-values)

¿Por qué? Todo análisis de datos —y todo Machine Learning— es probabilístico.

Primera Parte: Fundamentos de Probabilidad

Empecemos con una pregunta

Lanzamos una moneda justa 10 veces. ¿Cuántas caras esperáis?

```
import numpy as np
np.random.seed(42)
lanzamientos = np.random.choice(["cara", "cruz"], size=10)
print(lanzamientos)
print("Caras:", (lanzamientos == "cara").sum())
```

Resultado:

```
['cara' 'cruz' 'cara' 'cara' 'cara' 'cruz' 'cruz' 'cara' 'cruz' 'cara']
Caras: 6
```

¿Qué Es la Probabilidad?

Definición: medida de la incertidumbre de que ocurra un evento

Rango: 0 a 1

- $P = 0$: imposible
- $P = 1$: seguro
- $0 < P < 1$: incierto

Visión frecuentista: la probabilidad es la frecuencia relativa a largo plazo

$$P(\text{cara}) \approx \frac{\text{n}^\circ \text{ de caras}}{\text{n}^\circ \text{ de lanzamientos}} \xrightarrow{n \rightarrow \infty} 0.5$$

La probabilidad emerge con muchas repeticiones

```
for n in [10, 100, 10000]:  
    lanz = np.random.choice([0, 1], size=n)    # 1 = cara  
    print(f"n={n:>6}: P(cara) ≈ {lanz.mean():.3f}")
```

n= 10: P(cara) ≈ 0.600

n= 100: P(cara) ≈ 0.490

n= 10000: P(cara) ≈ 0.503

Ley de los grandes números: cuantas más repeticiones, más se acerca la frecuencia observada a la probabilidad teórica.

Reglas Básicas de Probabilidad (1/2)

1. Regla de la suma (eventos mutuamente excluyentes)

$$P(A \cup B) = P(A) + P(B)$$

Ejemplo: sacar un 1 o un 2 en un dado = $1/6 + 1/6 = 1/3$

2. Regla del producto (eventos independientes)

$$P(A \cap B) = P(A) \cdot P(B)$$

Ejemplo: dos caras seguidas = $\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$

Reglas Básicas de Probabilidad (2/2)

3. Probabilidad complementaria

$$P(\tilde{A}) = 1 - P(A)$$

Ejemplo: si $P(\text{lluvia}) = 0.3$, entonces $P(\text{no lluvia}) = 0.7$

Truco útil: a veces es más fácil calcular "lo contrario".

$P(\text{al menos una cara en 3 lanzamientos}) = 1 - P(\text{ninguna cara}) = 1 - (1/2)^3 = 7/8$

Eventos Independientes vs Dependientes

Independientes: un evento no afecta al otro

- Lanzar dos monedas
- Dos tiradas de dado

Dependientes: un evento afecta al otro

- Sacar dos cartas sin reemplazo
- Probabilidad de cancelación según la temporada

Probabilidad Condicional

$P(A \mid B)$: probabilidad de A **dado que** B ya ocurrió

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Ejemplo con datos reales (viviendas Barcelona):

- $P(\text{precio} > 400k) \approx 0.34$
- $P(\text{precio} > 400k \mid \text{Eixample}) \approx 0.60$

Interpretación: saber que el piso está en el Eixample **cambia** la probabilidad.



Ahora al notebook

**Probabilidades sobre datos reales
(20 minutos)**

Variable Aleatoria

Es una cantidad X cuyo valor depende de un fenómeno aleatorio.

Discretas:

- 0 si sale cara, 1 si sale cruz
- El resultado de lanzar un dado (1-6)
- N° de cancelaciones en un día

Continuas:

- La altura de una persona al azar
- El precio de un piso
- La temperatura de mañana

Distribución de Probabilidad

La **distribución** de X es la ley que asigna probabilidades a sus valores.

Ejemplo: dado justo → distribución **uniforme** discreta

```
import plotly.express as px
caras = [1, 2, 3, 4, 5, 6]
probs = [1/6] * 6
px.bar(x=caras, y=probs, title="Dado justo: distribución uniforme")
```

Todos los resultados son igual de probables: $P(1) = \dots = P(6) = 1/6$.

Distribución de Bernoulli y Binomial

Bernoulli: un único ensayo con dos resultados (éxito/fracaso), prob. p

- ¿El cliente cancela? ¿Sale cara?

Binomial: n° de éxitos en n ensayos independientes

```
from scipy import stats
# N° de caras en 10 lanzamientos de moneda justa
dist = stats.binom(n=10, p=0.5)
print("P(exactamente 6 caras) =", round(dist.pmf(6), 3))    # 0.205
print("P(6 o más caras)          =", round(1 - dist.cdf(5), 3)) # 0.377
```



Descanso de 30 minutos

Nos vemos a las 11:15 para la distribución normal.

Segunda Parte: La Distribución Normal

La Distribución Normal

Distribución **continua** que depende sólo de dos parámetros:

- μ : media (centro)
- σ : desviación estándar (dispersión)

$$X \sim N(\mu, \sigma)$$

Ejemplo: altura de mujeres españolas $\sim N(163, 6)$

- Media: 163 cm · Desviación estándar: 6 cm

Forma de campana simétrica: media = mediana = moda, en el centro.

¿Por qué es tan importante?

- Muchos fenómenos naturales la siguen (alturas, errores de medición)
- Es la base de la mayoría de tests estadísticos (Día 6)
- **Teorema Central del Límite**: la media de muchas muestras tiende a ser normal, *aunque los datos originales no lo sean*

La normal estándar $N(0, 1)$ es la referencia: cualquier $N(\mu, \sigma)$ se obtiene como $N(0, 1) \cdot \sigma + \mu$.

pdf, cdf y ppf con `scipy.stats`

```
from scipy import stats
N = stats.norm(loc=163, scale=6)    #  $N(\mu=163, \sigma=6)$ 

N.pdf(163)                          # densidad en el centro (altura de la curva)
N.cdf(170)                          #  $P(X \leq 170) \rightarrow \sim 0.88$ 
N.ppf(0.95)                         # percentil 95  $\rightarrow \sim 172.9$  (inverso de cdf)
```

- **pdf**: la curva de campana
- **cdf**: probabilidad acumulada
 $P(X \leq x)$
- **ppf**: el valor para una probabilidad dada
(cuantil)

Regla Empírica (68-95-99.7)

Para una distribución **normal**:

- **68%** de los datos dentro de $\mu \pm 1\sigma$
- **95%** dentro de $\mu \pm 2\sigma$
- **99.7%** dentro de $\mu \pm 3\sigma$

Usos:

- Detectar outliers (fuera de $\mu \pm 3\sigma$ es muy raro)
- Estimar rangos típicos
- Base de los intervalos de confianza (Día 6)

Estandarización (Z-Score)

Cuántas desviaciones estándar separa un valor de la media:

$$z = \frac{x - \mu}{\sigma}$$

- $z = 0 \rightarrow$ el valor es la media
- $z = 1 \rightarrow 1\sigma$ por encima de la media
- $z = -2 \rightarrow 2\sigma$ por debajo

```
from scipy import stats
z_scores = stats.zscore(df["price"])
extremos = df[abs(z_scores) > 3]    #  $|z| > 3$  es muy raro
```



**Ahora al
notebook**

**Distribución normal y z-scores
(25 minutos)**

¿Son normales los precios de Barcelona?

```
mu, sigma = df["price"].mean(), df["price"].std()
for k in (1, 2, 3):
    dentro = df["price"].between(mu - k*sigma, mu + k*sigma).mean()
    print(f"μ ± {k}σ: {dentro:.1%} (normal esperaba 68/95/99.7%)")
```

μ ± 1σ: 87.0% (normal esperaba 68%)

μ ± 2σ: 94.6%

μ ± 3σ: 97.8%

Conclusión: los precios **no** son normales — tienen asimetría a la derecha (pocos pisos muy caros) : Los datos reales rara vez son perfectamente normales!

Resumen del Día 4

1. ✓ Probabilidad: incertidumbre entre 0 y 1; frecuencia a largo plazo
2. ✓ Reglas: suma, producto, complemento; condicional
3. ✓ Variables aleatorias y distribuciones (uniforme, binomial)
4. ✓ Distribución normal: μ , σ y la regla 68-95-99.7
5. ✓ `scipy.stats`: pdf, cdf, ppf, z-scores
6. ✓ Datos reales rara vez son perfectamente normales

Mañana (Día 5): estadísticos de resumen — describir datos con números.

Gracias!