

Business Analytics & Data Science

Día 5: Estadísticos de Resumen

EAE Business School Barcelona

8 de junio de 2026

Plan del Día 5

Primera Parte (8:30-10:45)

1. ¿Qué es la estadística descriptiva?
2. Medidas de tendencia central
3. Medidas de dispersión
4. Cuartiles, percentiles y outliers

Segunda Parte (11:15-13:30)

1. Análisis de frecuencias
2. Correlación entre variables
3. Matriz de correlación
4. Correlación $\neq$ causalidad + evaluación

Empecemos observando

Una sola línea resume 1000 pisos de Barcelona:

```
df["price"].describe()
```

count	998	
mean	448,640	← media
std	448,499	← dispersión enorme
min	39,000	
50%	300,000	← mediana (¡muy por debajo de la media!)
max	3,995,000	

Primera Parte: Describir los Datos

¿Qué Es la Estadística Descriptiva?

Objetivo: resumir y describir un conjunto de datos con pocos números.

Dos grandes preguntas:

1. **Tendencia central:** ¿dónde está el "centro" de los datos?
2. **Dispersión:** ¿qué tan dispersos están?

Analogía inmobiliaria:

- Tendencia central = ¿cuál es el precio típico?
- Dispersión = ¿los precios son parecidos o muy variables?

Medidas de Tendencia Central

```
df["price"].mean()      # Media: suma / cantidad  
df["price"].median()    # Mediana: valor central al ordenar  
df["price"].mode()      # Moda: valor más frecuente
```

- **Media:** usa todos los valores, pero le afectan los extremos
- **Mediana:** el valor del medio, robusta a outliers
- **Moda:** el más repetido (útil en categóricas)

Media vs Mediana: ¿Cuándo Cada Una?

Salarios en una empresa: 25k, 28k, 30k, 32k, 35k, **500k** (CEO)

- **Media** = $(25+28+30+32+35+500)/6 = \mathbf{108k}$
- **Mediana** = $(30+32)/2 = \mathbf{31k}$

¿Cuál representa el salario "típico"? → la mediana

Regla: con datos asimétricos o con outliers (precios, salarios, ingresos), la mediana describe mejor el caso típico.

Medidas de Dispersión: ¿por qué importan?

Dos datasets con **la misma media** pueden ser muy distintos:

A: 10, 10, 10, 10, 10 → media = 10, dispersión = 0

B: 0, 5, 10, 15, 20 → media = 10, dispersión alta

La media sola no basta: necesitamos saber cuánto varían los datos.

Rango, Varianza y Desviación Estándar

Rango = máximo – mínimo (fácil, pero muy sensible a extremos)

Varianza = promedio de las desviaciones al cuadrado

$$\text{Var} = \mathbb{E}[(x - \bar{x})^2]$$

Desviación estándar (σ) = raíz de la varianza → **mismas unidades que los datos**

$$\sigma = \sqrt{\text{Var}}$$

```
df["price"].std()
```

Cuartiles y Percentiles

Cuartiles dividen los datos ordenados en 4 partes:

- **Q1 (25%), Q2 (50%, mediana), Q3 (75%)**

```
df["price"].quantile([0.25, 0.5, 0.75])
```

Rango intercuartílico (IQR) = $Q3 - Q1$ → el 50% central de los datos.

Detectar Outliers con el IQR

Regla estándar: un valor es outlier si

- $\text{valor} < Q1 - 1.5 \times \text{IQR}$, o
- $\text{valor} > Q3 + 1.5 \times \text{IQR}$

```
Q1, Q3 = df["price"].quantile([0.25, 0.75])  
IQR = Q3 - Q1  
outliers = df[(df["price"] < Q1 - 1.5*IQR) |  
               (df["price"] > Q3 + 1.5*IQR)]
```

Esto es exactamente lo que dibuja un box plot.



Ahora al notebook

**Tendencia central, dispersión y
outliers (25 minutos)**



Descanso de 30 minutos

Nos vemos a las 11:15 para frecuencias y correlación.

Segunda Parte: Frecuencias y Relaciones

Análisis de Frecuencias

Para variables **categóricas**, resumimos contando:

```
df["neighborhood"].value_counts()           # frecuencias absolutas  
df["neighborhood"].value_counts(normalize=True) # frecuencias relativas (%)
```

Eixample	0.21
Sant Martí	0.13
Sants - Montjuïc	0.12
...	

Tabla de frecuencias = la base para entender una variable categórica.

Visualizar Frecuencias

```
import plotly.express as px
conteo = df["type"].value_counts().reset_index()
px.bar(conteo, x="type", y="count", title="Tipos de propiedad")
```

Para variables **numéricas**, el histograma agrupa en intervalos (bins):

```
px.histogram(df, x="price", nbins=50, title="Distribución de precios")
```

El histograma muestra la **forma** de la distribución: simetría, colas, picos.

Resúmenes por Grupo

Combinar frecuencias con agregación responde preguntas de negocio:

```
df.groupby("neighborhood")["price"].agg(["mean", "median", "count"])
```

	mean	median	count
Sarrià - Sant Gervasi	1,036,809	...	...
Eixample	613,784	...	...
Nou Barris	170,363	...	...

¿Qué barrios son más caros? ¿Dónde hay más oferta?

Correlación Entre Variables

Correlación: mide la relación **lineal** entre dos variables numéricas.

```
df["price"].corr(df["sqrmsts"])    # ≈ 0.77
```

Rango: -1 a +1

- **+1:** positiva perfecta (X sube → Y sube)
- **0:** sin relación lineal
- **-1:** negativa perfecta (X sube → Y baja)

$ \rho $	Interpretación
> 0.7	fuerte
$0.4 - 0.7$	moderada
< 0.4	débil

Matriz de Correlación

```
cols = ["price", "sqrmts", "rooms", "bathrooms", "floor"]
corr = df[cols].corr()

import plotly.express as px
px.imshow(corr, text_auto=".2f", color_continuous_scale="RdBu_r",
          zmin=-1, zmax=1, title="Matriz de Correlación")
```

De un vistazo: qué variables se mueven juntas. Útil **antes** de modelar (Machine Learning) para anticipar qué predictores son informativos.



Correlación NO Implica Causalidad

Ejemplo clásico: fuerte correlación entre venta de helados e incendios forestales.

¿El helado causa incendios? **No.** Hay una variable oculta: la **temperatura** (más calor → más helados y más incendios).

La causalidad requiere un análisis mucho más profundo.

Más ejemplos absurdos: Spurious Correlations



**Ahora al
notebook**

**Frecuencias y correlaciones (20
minutos)**

Resumen del Día 5

1.  Tendencia central: media, mediana, moda (y cuándo usar cada una)
2.  Dispersión: rango, varianza, desviación estándar, IQR
3.  Cuartiles y detección de outliers
4.  Análisis de frecuencias (absolutas, relativas, por grupo)
5.  Correlación, matriz de correlación
6.  Correlación $\neq$ causalidad

Mañana (Día 6): inferencia — de la muestra a la población, intervalos de confianza y p-values.

Gracias!