

Business Analytics & Data Science

Día 6: Inferencia Estadística

EAE Business School Barcelona

9 de junio de 2026

Plan del Día 6

Primera Parte (8:30-10:45)

1. De muestra a población
2. Intervalos de confianza
3. Introducción a tests de hipótesis

Segunda Parte (11:15-13:30)

1. T-tests en práctica
2. Test chi-cuadrado
3. Patrón de análisis + evaluación

Recap del Bloque de Estadística

Día 4: probabilidad, distribuciones, la normal y la regla 68-95-99.7

Día 5: estadísticos de resumen (media, dispersión, correlación)

Hoy: usamos la estadística para **tomar decisiones** con datos —
y para saber cuánta confianza merece cada conclusión.

Primera Parte: De Muestra a Población

El Problema de Inferencia

Pregunta de negocio: ¿cuál es el precio medio de los pisos en Barcelona?

Problema: no tenemos los datos de *todos* los pisos (la población completa).

Solución: medimos una **muestra** e **inferimos** sobre la población.

Inferencia estadística = afirmar algo sobre la población a partir de una muestra, cuantificando la incertidumbre.

Población vs Muestra

Población = todos los elementos de interés (todos los pisos de Barcelona, ~500k)

Muestra = el subconjunto que medimos (los 1000 del dataset)

- **Parámetro** = característica de la población (μ, σ)
- **Estadístico** = característica de la muestra ($\bar{x}, s$)

Objetivo: usar el estadístico muestral para estimar el parámetro poblacional.

Distribución Muestral y Error Estándar

Si tomáramos muchas muestras, cada una daría una media distinta. La distribución de esas medias es la **distribución muestral**.

Teorema Central del Límite: con $n > 30$, la distribución muestral de la media es aproximadamente normal, *aunque los datos originales no lo sean*.

Error estándar:

$$SE = \frac{\sigma}{\sqrt{n}}$$

A mayor n , menor $SE \rightarrow$ estimaciones más precisas.

Intervalos de Confianza

Un **intervalo de confianza (IC)** es un rango donde creemos que está el parámetro.

Para la media, al 95%:

$$IC = \bar{x} \pm 1.96 \cdot SE = \bar{x} \pm 1.96 \cdot \frac{\sigma}{\sqrt{n}}$$

Interpretación correcta: "si repitiéramos el muestreo muchas veces, el 95% de los intervalos contendrían el verdadero valor poblacional".

Interpretación INCORRECTA: "hay un 95% de probabilidad de que μ esté aquí".

Calcular un IC en Python

```
from scipy import stats
import numpy as np

precios = df["price"].dropna()
n = len(precios)
media = precios.mean()
se = precios.std() / np.sqrt(n)

ic = stats.t.interval(0.95, df=n-1, loc=media, scale=se)
print(f"Media: {media:.0f}€")
print(f"IC 95%: [{ic[0]:.0f}, {ic[1]:.0f}]")
```



**Ahora al
notebook**

**Intervalos de confianza (25
minutos)**

Tests de Hipótesis: el concepto

Pregunta: ¿el precio medio en el Eixample es distinto del de Sants?

1. **H₀ (nula):** no hay diferencia ($\mu_{Eix} = \mu_{Sants}$)
2. **H₁ (alternativa):** sí la hay ($\mu_{Eix} \neq \mu_{Sants}$)
3. **Recoger datos** y calcular un estadístico
4. **Calcular el p-value:** ¿qué probable es ver estos datos si H₀ fuera cierta?
5. **Decidir:** si p-value < 0.05 → rechazamos H₀

P-value: Interpretación

p-value = probabilidad de observar datos tan extremos (o más) **si H_0 es cierta**

Regla común: $\alpha = 0.05$

- $p < 0.05 \rightarrow$ rechazamos $H_0 \rightarrow$ "estadísticamente significativo"
- $p \geq 0.05 \rightarrow$ no rechazamos $H_0 \rightarrow$ no hay evidencia suficiente

Correcto: "si no hubiera diferencia real, veríamos datos así solo el 5% de las veces"

Incorrecto: "hay un 5% de probabilidad de que H_0 sea cierta"



"No significativo" $\neq$ "No hay efecto"

No rechazar H_0 **no demuestra** que H_0 sea cierta: quizá el efecto existe pero la muestra es pequeña o ruidosa.

Hoy veremos **los dos casos en datos reales**:

- Cancelación vs tipo de depósito $\rightarrow$ diferencia **significativa** ($p \approx 0.003$)
- Precio medio (ADR) ciudad vs resort $\rightarrow$ **no** significativa ($p \approx 0.16$)

Ambos resultados son válidos y útiles: la estadística también nos dice cuándo **no** podemos concluir.

Errores en Tests de Hipótesis

	H_0 verdadera	H_0 falsa
Rechazamos H_0	 Error Tipo I (falso positivo)	 Correcto
No rechazamos H_0	 Correcto	 Error Tipo II (falso negativo)

- **Tipo I:** afirmar un efecto que no existe (controlado por α)
- **Tipo II:** no detectar un efecto que sí existe (relacionado con el poder)

Trade-off: reducir uno aumenta el otro.

Segunda Parte: Tests Estadísticos en Práctica

T-test: Una Muestra

Pregunta: ¿el precio medio es distinto de 300.000€?

H₀: $\mu = 300000$ · **H₁:** $\mu \neq 300000$

```
from scipy import stats
t_stat, p_value = stats.ttest_1samp(df["price"].dropna(), 300000)
print(f"t = {t_stat:.3f}, p = {p_value:.4g}")

if p_value < 0.05:
    print("Rechazamos H0: el precio medio difiere de 300k")
else:
    print("No rechazamos H0")
```


T-test: Dos Muestras Independientes

Pregunta: ¿los pisos con terraza son más caros?

```
con = df[df["terrace"] == 1]["price"].dropna()
sin = df[df["terrace"].fillna(0) == 0]["price"].dropna()

t_stat, p_value = stats.ttest_ind(con, sin, equal_var=False)
print(f"Con terraza: {con.mean():.0f}€ | Sin: {sin.mean():.0f}€")
print(f"p = {p_value:.4g}")
```

Siempre visualizar primero (box plot) para entender la magnitud del efecto antes de mirar el p-value.

Test Chi-Cuadrado: Variables Categóricas

Pregunta: ¿hay asociación entre el barrio y el tipo de propiedad?

```
tabla = pd.crosstab(df["neighborhood"], df["type"])
chi2, p_value, dof, esperado = stats.chi2_contingency(tabla)
print(f"χ² = {chi2:.2f}, p = {p_value:.4g}")

if p_value < 0.05:
    print("Hay asociación significativa entre barrio y tipo")
```

χ^2 compara las frecuencias **observadas** con las **esperadas** bajo independencia.

Supuestos de los Tests

T-test:

- Datos aproximadamente normales (o $n > 30$, por el TCL)
- Muestras independientes

Chi-cuadrado:

- Frecuencias esperadas > 5 en cada celda
- Observaciones independientes

Si no se cumplen, el test no es fiable: hay que usar alternativas (p. ej. tests no paramétricos).

Patrón de Análisis Estadístico

1. Pregunta de negocio

"¿Los pisos con parking son más caros?"

2. Explorar datos

- Box plots
- Estadísticas descriptivas

3. Elegir y aplicar el test

- T-test de dos muestras
- Verificar supuestos

4. Interpretar

- p-value y significancia
- Tamaño del efecto (diferencia práctica)
- **Escribir la conclusión en lenguaje de negocio**

Significancia vs Importancia Práctica

Significancia estadística ($p < 0.05$): "hay evidencia de diferencia". Con muestras grandes, hasta diferencias minúsculas salen significativas.

Importancia práctica: "la diferencia es lo bastante grande como para importar".

*Una diferencia de 1.000€ puede ser estadísticamente significativa pero irrelevante para el negocio. **Reportad siempre ambos:** p-value y magnitud.*

Buenas Prácticas

- ✓ Visualizar antes de testear
- ✓ Verificar los supuestos del test
- ✓ Reportar el IC además del p-value
- ✓ Considerar la importancia práctica, no solo la estadística
- ✗ No buscar p-values hasta dar con $p < 0.05$ (*p-hacking*)
- ✗ No hacer muchos tests sin corrección
- ✗ No leer "no significativo" como "no hay efecto"



**Ahora al
notebook**

**Tests de hipótesis + evaluación
(40 minutos)**

Gracias!